Resumen ejecutivo — Resultados de todas las fases

Fase 0 — Definición Problema: clasificación binaria de fraude en e-commerce (Vesta Corp). Desbalance 28:1 → métrica primaria AUC-PR, no Accuracy. Nivel Gartner: los 4 niveles requeridos (descriptivo → prescriptivo).

Fase 1 — EDA Dataset completo: 590,540 × 434. Muestra EDA: 15,675 × 441. Hallazgo crítico: MNAR confirmado en variables de identidad (fraude 31.77% con identidad vs 10.59% sin ella, ratio 3×). TransactionAmt con skewness=5.60 → log1p obligatorio. ProductCD=C con 40.96% de fraude (11.7× la tasa base). Top correlaciones Spearman: V258 (+0.528), V257 (+0.518). 7 features generadas.

Fase 2 — Missingness 4 mecanismos diagnosticados con Chi^2: MCAR (tarjetas 0.5%), MAR (D, M, V usables, addr), MNAR confirmado (id_01–id_38, 82% miss), MNAR probable (V151–V339, 58.7%). Decisión crítica: 0 imputaciones en variables id_. 7 transformaciones registradas en log. df_v02_clean: 15,675 × 460 (+19 features).

Fase 3 — Outliers 0 filas eliminadas. Tres métodos por justificación técnica: MAD para TransactionAmt (skewness=5.60), IQR Tukey para variables C y D (no paramétricas), Isolation Forest multivariado para Vesta (193 variables). Hallazgo más discriminativo: flag_iso_vesta con 7.51% de fraude vs 3.5% base (ratio 2.15×). df_v03_clean: 590,540 × 469 (+7 flags).

Fase 4 — Calidad ISO 25012 Score global: 92.88% sobre 590,540 registros. Unicidad 100% (0 duplicados), Validez 100% (0 violaciones de rango), Consistencia 100% (4 reglas lógicas verificadas). Completitud 70.25% — explicada íntegramente por NaN intencional MNAR en id_; score real de variables tratadas ~99%+. JSON auditable exportado.

Fase 5 — Feature Engineering Split temporal 80/20 por TransactionDT. Rare Encoding (n<100→'rare') + Target Encoding (smoothing=10) en 5 variables categóricas. PCA sobre 169 variables Vesta → 5 componentes con 95% de varianza (multicolinealidad extrema confirmada). RobustScaler en variables numéricas. Anti-leakage verificado en 5 puntos. Dataset final: X_train (64,006 × 305), X_test (16,002 × 305).

```
╔═══════════════════════════════════════════════════════════════╗
‖           PIPELINE DD v3.0 — IEEE-CIS FRAUD DETECTION         ‖
╚═══════════════════════════════════════════════════════════════╝

RAW DATA
  train_transaction.csv (590,540 × 394)
  train_identity.csv    (144,233 × 41)
          |
          ▼ LEFT JOIN on TransactionID
  df_v01_raw (590,540 × 434)
          |
╔═══════╧═══════════════════════════════════════════════════╗
‖  FASE 1 — EDA                                              ‖
‖  • Estructura, tipos, duplicados, unicidad                 ‖
‖  • Análisis univariado (skewness, curtosis, KDE)           ‖
‖  • Correlaciones Spearman (no-normalidad confirmada)       ‖
‖  • Patrones temporales, categóricas, MNAR preliminar       ‖
‖  + 7 features: log_amt, hora, dia, nocturno,               ‖
‖    flag_amt_outlier, flag_tiene_identidad                   ‖
‖  → df_v01_raw (15,675 × 441) [muestra EDA]                 ‖
╚═══════╤═══════════════════════════════════════════════════╝
          |
╔═══════╧═══════════════════════════════════════════════════╗
‖  FASE 2 — MISSINGNESS                                       ‖
‖  • Chi² máscara miss vs isFraud → MCAR/MAR/MNAR            ‖
‖  • missingno: matrix, heatmap, dendrogram                  ‖
‖  • 7 tratamientos diferenciados por mecanismo              ‖
‖  + 14 flag_miss_D, vesta_density, 4 flag_miss_addr         ‖
‖  → df_v02_clean (15,675 × 460)                             ‖
╚═══════╤═══════════════════════════════════════════════════╝
          |
╔═══════╧═══════════════════════════════════════════════════╗
‖  FASE 3 — OUTLIERS                                          ‖
‖  • MAD ModZ>3.5 → TransactionAmt                            ‖
‖  • IQR Tukey → Variables C (conteo)                        ‖
‖  • Isolation Forest (193 V, contamination=0.035)           ‖
‖  + flag_iso_vesta, iso_score_vesta, flag_outlier_Ci        ‖
‖  → df_v03_clean (590,540 × 469) — 0 filas eliminadas       ‖
╚═══════╤═══════════════════════════════════════════════════╝
          |
╔═══════╧═══════════════════════════════════════════════════╗
‖  FASE 4 — CALIDAD ISO 25012                                 ‖
‖  • 6 dimensiones evaluadas sobre 590,540 registros         ‖
‖  • Unicidad 100% · Validez 100% · Consistencia 100%        ‖
‖  • Completitud 70.25% (NaN intencional MNAR)               ‖
‖  • Score global: 92.88%                                    ‖
‖  → reporte_calidad_ISO25012.json                           ‖
╚═══════╤═══════════════════════════════════════════════════╝
          |
╔═══════╧═══════════════════════════════════════════════════╗
‖  FASE 5 — FEATURE ENGINEERING                               ‖
‖  • Split temporal 80/20 por TransactionDT [PRIMERO]        ‖
‖  • Rare Encoding n<100 → 'rare'                            ‖
‖  • Target Encoding smoothing=10 (fit en train)             ‖
‖  • Label Encoding M y id_ categóricas                      ‖
‖  • PCA: 169 vars V → 5 componentes (95% var.)              ‖
‖  • RobustScaler variables numéricas (fit en train)         ‖
‖  → X_train (64,006 × 305) | X_test (16,002 × 305)          ‖
╚═══════╤═══════════════════════════════════════════════════╝
```

Comparativa — Datos originales vs. post-pipeline

Dimensión	Datos originales	Post-pipeline	Decisión
Shape	590,540 × 434	X_train 64,006 × 305 / X_test 16,002 × 305	Split temporal + reducción dimensional PCA
Filas eliminadas	—	0	Todos los outliers conservados con flags
TransactionAmt	Skewness=5.60, no-normal	log1p aplicado → skewness ~0.8	Anderson-Darling confirmó no-normalidad
Variables Vesta (V)	339 variables brutas	5 componentes PCA (169 usables + vesta_density)	Multicolinealidad extrema → 97% reducción
Variables id_ (38)	82% NaN — mecanismo desconocido	NaN intencional MNAR confirmado — conservadas	Chi² p<<0.001, ratio fraude 3×
Variables D (15)	57% NaN promedio — causa desconocida	Imputadas con mediana + 14 flags miss	MAR confirmado: depende de historial tarjeta
Variables M (9)	51.8% NaN	NaN → 'Unknown' (categoría semántica)	Sin historial = sin match = categoría válida
Variables C (14)	0% NaN — sin análisis outlier	Escaladas + 4 flags outlier informativos	IQR: C1,C2,C6,C11 con ratio fraude >1.3×
ProductCD	Categórica nominal 5 cats	Target Encoded (0.035–0.410 rango fraude)	C=40.96% fraude → alta discriminación
EmailDomain	Alta cardinalidad, NaN	Rare(n<100→'rare') + Target Encoded	Hotmail 22.67%, Gmail 20.51% fraude
Temporalidad	TransactionDT — timedelta crudo	hora_dia, dia_semana, dia_mes, es_nocturno	Fraude concentrado 18h–23h
Outliers monto	Identificados, sin tratamiento	flag_amt_outlier (MAD ModZ>3.5)	21.79% fraude en outliers → conservar
Outliers Vesta	No analizados	flag_iso_vesta + iso_score_vesta	7.51% fraude en outliers (ratio 2.15×)
Calidad global	No evaluada	ISO 25012: 92.88%	Unicidad/Validez/Consistencia = 100%
Features totales	434 originales	305 finales (26 nuevas, PCA redujo Vesta)	Neto: -129 cols brutas, +26 informativas

Salidas del analisis de datos:

ieee_cis_train_ml.csv → (64,006 × 306) X_train + isFraud

ieee_cis_test_ml.csv → (16,002 × 306) X_test + isFraud

Pipeline para el modelamiento en ML

1. Métrica primaria → AUC-PR (no Accuracy)
2. Baseline primero → DummyClassifier estratificado
3. Desbalance → class_weight='balanced' antes de SMOTE
4. NaN en id_ → usar LightGBM/XGBoost (manejan nulos nativamente)
5. Evaluar en test → una sola vez al final, nunca durante tuning
6. Optimización → Optuna (Bayesian), no GridSearch (inviable con 305 features)
7. Interpretabilidad → SHAP values sobre el modelo final